Anexo C. Conjunto de datos de plagas y enfermedades

Este anexo documenta el conjunto usado para entrenar PLAGASX v8, el modelo desplegado en el robot, y los cambios de v9. Se reconstruyó a partir del dataset generado (`dataset_combinado`) y del cuaderno de Kaggle `davidgomez32/plagasx`.

C.1 Clases

Tabla C-1. Clases y número de cajas en PLAGASX v8. Una imagen puede tener varias cajas.

Id	Clase	Entrenamiento	Validación	Prueba
0	`col_sana`	144	41	15
1	`col_amarillamiento`	16	4	5
2	`col_manchas_cafe`	142	41	30
3	`col_dano_insecto`	6 555	884	718
4	`col_mildiu_velloso`	199	64	27
5	`col_malformacion`	143	39	18
6	`col_pudricion`	0	0	0
7	`col_mosca_blanca`	1 169	241	230
8	`col_pulgon`	1 176	78	67
9	`col_oruga`	742	76	72
10	`col_pulguilla`	357	12	15
11	`col_trips` (solo v9)	—	—	—

La clase `col_pudricion` existe pero no tuvo ninguna imagen: el modelo v8 no puede detectarla. El conjunto está muy desbalanceado: `col_dano_insecto` concentra la mayoría de las cajas, y `col_amarillamiento` solo tiene 25.

C.2 Partición de entrenamiento, validación y prueba

Tabla C-2. Imágenes por origen y partición en v8.

Origen	Contenido	Entrenamiento	Validación	Prueba	Regla de partición
`mio`	Fotos propias de coles	120	33	17	Conserva la partición de origen del dataset propio
`caj`	Cajas reales de daño y mosca blanca	1 654	271	268	Conserva la partición de origen
`ip`	IP102, plagas seleccionadas	1 819	127	124	train → entrenamiento; valid → alterna validación y prueba
`ext`	Datasets externos de coliflor y col	700	200	100	Aleatoria 70/20/10 con semilla 42

`fondo`	Senderos propios sin enfermedad	96	24	0	Una de cada 5 a validación
`negint`	Negativos de interior y exterior	258	87	86	Cíclica: validación, prueba y tres a entrenamiento
Total		**4 647**	**742**	**595**	

Las imágenes sin cajas enseñan al modelo qué no es plaga: 460 en entrenamiento, 125 en validación y 107 en prueba.

Riesgos de esta partición.

- **Fuga en `ext`.** La partición es aleatoria por imagen y parte de estos datasets contiene variantes aumentadas de una misma foto. Las métricas de ese origen pueden ser optimistas.
- **Fotos cercanas en `mio`.** No se separó por planta ni por sesión.
- **Resultados de referencia.** mAP50 de 0,843 y top-1 de 0,932 corresponden a esta prueba, no a fotos nuevas del robot.

C.3 Tipos de anotación

Origen	Tipo de caja	Fiabilidad
`mio`	Automática, por color	**Baja:** muchas cajas abarcan la imagen o zonas sin daño
`ext`	Imagen completa	Sirve para clasificar, no para localizar
`caj`	Dibujada por los autores de cada dataset	Alta en localización. Las de mosca blanca son mayormente de otros cultivos
`ip`	Dibujada (IP102)	Alta en localización; varias especies no son de coles
Anotación manual propia	`etiquetar.html`	A la fecha hay 61 fotos revisadas y solo 1 caja

C.4 Ejemplos de anotaciones



Figura C-1. Cajas automáticas de las fotos propias. Se muestran tal como entraron al entrenamiento: varias no coinciden con un daño real.







Figura C-2. Cajas reales de daño de insecto en col y de mosca blanca en hojas de otro cultivo.

C.5 PLAGASX v9

La versión 9 se lanzó el 8 de noviembre de 2026 para coles y coliflores y estaba en entrenamiento al compilar este anexo. Sus resultados no se incluyen.

Aspecto	**v8**	**v9**
Clases	11	12 (añade `col_trips`)
Detector	yolov8s, 800 px	yolo11m, 960 px, 2 GPU T4
Clasificador	yolov8s-cls, 224 px	yolo11m-cls, 320 px
Máximo por clase externa	200	500

Las imágenes de `col_trips` provienen de IP102 y son de cereales y mango, **ninguna de coles**. Un buen resultado en esa clase no demuestra que detecte trips en coles o coliflores.

C.6 Trabajo pendiente

La prueba P6 exige etiquetar 150 fotos del robot sin ver la salida del modelo. Es el dato que falta para afirmar la exhaustividad en plantas reales. Desde el 8 de noviembre, `etiquetar.html` admite etiquetas ilimitadas y muestra las fotos de la misión «Recoger dataset de plantas».